



星

星途-RAG 知识库平台

企业知识治理与 RAG 质量运营中台

产品需求文档 · 作品集展示版 V1.0

产品负责人 / 作者: wzp
更新日期: 2026-09-01
文档状态: 产品方案稿

01 产品概述

背景 · 定位 · 目标 · 范围



项目概览

一句话看懂这个项目在解决什么

星途-RAG 是位于企业内容源、RAG 引擎与智能应用之间的知识治理中台。

平台负责：知识库、文档、版本、审核、权限、入库、验收、检索、评测、发布与运营。

RAG 引擎负责：解析、切片、向量化、索引、召回、重排与答案生成。

智能应用负责：面向最终用户的对话体验、业务流程与实时系统能力。

产品愿景：让每一项有效知识有来源、有版本、有负责人、可验证、可追溯。

V1.0 范围

知识治理闭环 · 测试/生产隔离 · 多引擎适配

核心价值

把 RAG Demo 变成可长期运营的企业能力

交付物

PRD · 高保真原型 · 评测机制 · Bad Case 复盘

建设背景与核心问题

企业接入大模型后，知识治理比模型选择更关键

知识分散

资料散落在文件服务器、个人电脑与业务系统

版本混乱

缺少生效范围、有效期与责任人

发布失控

内容未经审核，过期知识难以及时下线

追溯困难

大模型回答与原始依据割裂

质量黑盒

解析、切片、召回效果缺少可视化验证

环境混用

测试知识与生产知识边界不清

因此建设星途-**RAG**，将企业知识转化为可治理、可检索、可评测、可审计、可复用的智能资产。

建设目标

业务 · 体验 · 质量三维目标

业务目标

统一知识资产 · 建立审核发布机制 · 支撑多智能产品复用 · 问题案例闭环

体验目标

非技术人员可独立完成运营 · 待办风险一屏可见 · 检索结果可解释 · 失败可执行

质量目标

答案具备有效引用 · 无知识时明确兜底 · 测试/生产严格隔离 · 高风险不得发布

范围内：知识库与版本、审核与验收、检索调试、批量评测、权限审计、多引擎配置。

范围外：自研 OCR/Embedding/向量库、完整 OA 审批、研发工单系统、实时业务数据中心、终端客服界面。

02 用户与架构

角色 · 场景 · 四层架构 · 信息架构

用户角色与核心场景

内容正确性、加工质量、回答质量由不同角色负责

知识运营

上传、元数据、验收、检索调试、生命周期

业务审核人

确认事实、范围、风险口径；职责隔离

AI 产品/测试

评测集、冒烟/回归、发布门槛判断

应用负责人

接入智能应用并反馈线上效果

系统管理员

成员、权限、引擎连接、密钥、审计

只读审计员

查看版本、审批、评测与发布证据

产品架构与边界

四层架构 · 职责清晰 · 引擎可替换

应用交付层

智能客服 · 员工助手 · 项目助手 · 销售助手 · 文档问答

星途知识治理层

知识库 · 文档版本 · 审核发布 · 权限 · 入库 · 检索评测 · 开放 API

RAG 能力层

解析 · OCR · Chunk · Embedding · 索引 · 混合检索 · Rerank · 生成

基础设施层

对象存储 · 数据库 · 日志监控 · SSO · 密钥管理

核心原则：测试/生产隔离 · 版本可追溯 · 审核/验收/评测独立 · 关键动作可审计 · 密钥不下发浏览器

信息架构

五大模块 · 覆盖知识运营全链路

运营总览

指标、待办、风险、最近活动

知识中心

知识库管理 · 文档与版本 · 数据源

治理流程

业务审核 · 入库任务 · 处理验收

质量中心

检索调试 · 批量评测 · 问题案例

系统管理

成员与权限 · RAG 引擎 · 审计日志

03 流程与功能

主流程 · 状态机 · 核心模块 · 质量机制



核心业务流程

从知识录入到生产发布的完整闭环

创建知识库 → 上传文档 → 提交审核 → 业务审核 → 测试入库 → 处理验收 → 检索验证 → 批量评测 → 发布审批 → 生产发布 → 应用调用 → 运营反馈



版本规则：已发布内容不可直接修改，必须创建新版本；旧版本停止生产召回但保留审计。

发布门槛：业务审核通过 + 处理验收通过 + Top K 命中 + P0 失败为 0 + 核心用例达标 + 阻断问题关闭 + 审批通过。

测试与生产资源严格隔离，未经评测的知识不得进入正式问答应用。

核心功能模块（P0）

13 个功能模块覆盖知识治理全链路

F-01 运营总览

指标、待办、漏斗、健康度

F-02 知识库管理

业务域、负责人、环境映射

F-03 文档与版本

上传、元数据、版本差异

F-05 业务审核

新旧对比、风险确认、职责隔离

F-06 入库任务

异步处理、幂等、回调验签

F-07 处理验收

Chunk 预览、数量一致性

F-08 检索调试

Top K、相关度、引用证据

F-09 批量评测

四阶段评测、发布门槛

F-10 问题案例

证据快照、修复回放

F-11 权限审计

角色矩阵、操作日志

F-12 RAG 引擎

多 Provider、测试/生产映射

质量保障机制

检索调试 ≠ 批量评测 ≠ 场景验证

1. 检索调试

有没有找到正确知识？ · Top K、相关度、来源、预期 Chunk

2. 冒烟评测

核心链路与 P0 安全是否正常？ · 5 条，P0 失败为 0

3. 正式评测

主要业务问法是否达标？ · 40 条，达到通过率门槛

4. 全量回归

新版本是否破坏已有能力？ · 200 条历史回归集

5. 场景验证

真实多轮对话是否可用？ · 客服/业务人工确认

失败案例自动生成问题记录，修复后必须回放原问题；P0 安全失败不可人工豁免发布。

04 质量与落地

非功能需求 · 运营指标 · 实施计划



非功能需求

性能 · 安全 · 可靠性 · 可观测性

性能

列表 P95 < 2s · 10 万文档搜索 P95 < 3s · 支持 2GB 上传 · 检索可用性 ≥ 99.9%

安全

SSO + MFA · 密钥服务端保管 · TLS · 越权防护 · 文件安全检查 · 全链路审计

可靠性

任务幂等 · 指数退避重试 · 回调补偿 · 原子切换与回滚 · 每日备份

可观测性

traceId 串联 · 任务/检索/模型消耗监控 · 积压与失败告警

运营指标体系

从知识供给到闭环效果的四维度量

知识供给

知识库数 · 已发布文档 · 更新及时率 · 过期占比 · 负责人覆盖率

流程效率

审核时长 · 入库成功率 · 上传至发布周期 · 驳回率

RAG 质量

Top K 命中 · 引用有效率 · 忠实度 · P0 失败 · 无答案率

闭环效果

新增案例 · 关闭时长 · 回放通过率 · 重复问题率 · 调用量

实施计划与风险

四阶段交付 · 八项风险对策

阶段一 1-2 周

PRD、原型、数据模型、权限矩阵、引擎适配方案

阶段二 4-6 周

知识库、审核、入库、验收、检索、权限审计、引擎对接

阶段三 2-3 周

评测集建设、内部应用试点、问题修复、上线验收

阶段四 持续

更多数据源与应用、质量告警、自动化回归、运营优化

知识责任不清 → 无负责人不得发布

历史资料污染 → 对话仅作参考

引擎锁定 → Provider Adapter

模型幻觉 → 强制引用 + 无知识兜底

权限泄露 → Chunk 级 ACL

评测失真 → 真实问法 + 人工复核

谢谢观看

星途-RAG：让每一次 AI 回答都建立在可信知识之上

作者：wzp · 配套交付：PRD · 交互原型 · Bad Case 复盘 · 演示